

SEGMENTAÇÃO DE VINHOS *

POR PERFIL QUÍMICO

INTRODUÇÃO

O Problema

A avaliação de vinhos é predominantemente subjetiva. Isso gera inconsistência na classificação e, mais grave, falhas na detecção de compostos nocivos em larga escala.

Objetivo

Desenvolver um sistema preditivo baseado em propriedades físico-químicas para classificar vinhos tintos de forma objetiva.

Solução

Utilizar o dataset Wine Quality para treinar modelos de Machine Learning capazes de identificar padrões de excelência e anomalias químicas.

JUSTIFICATIVA

- **Motivação de Saúde Pública:** o controle químico rigoroso não é apenas estético; é vital. Falhas no processo ou adulterações podem gerar altos níveis de Acidez Volátil ou contaminações por Metanol.
- A análise sensorial humana é incapaz de detectar certos riscos químicos sem expor o provador ao perigo.

Como Itália superou
'escândalo do vinho'
adulterado com metanol e
revolucionou mercado do país



O DATASET

Estrutura dos Dados:

11 Variáveis de Entrada (Features): Acidez Fixa, Acidez Volátil, Ácido Cítrico, Açúcar Residual, Cloretos, Dióxido de Enxofre Livre, Dióxido de Enxofre Total, Densidade, pH, Sulfatos e Álcool.

1 Variável de Saída (Target): Qualidade (score sensorial entre 0 e 10)

Características Importantes:

Dados multivariados com escalas distintas.

Classes desbalanceadas (muitos vinhos "médios", poucos "excelentes" ou "ruins").

Ausência de valores nulos (Dataset limpo).

PRÉ PROCESSAMENTO

Técnica 1: Padronização (StandardScaler)

O que faz: Ajusta os dados para média 0 e desvio padrão 1.

Justificativa: As variáveis possuem grandezas incompatíveis. O "Dióxido de Enxofre" varia na casa das centenas, enquanto "Cloretos" são decimais. Sem padronização, algoritmos baseados em distância (como K-Means) seriam enviesados pela variável de maior valor numérico.

PRÉ PROCESSAMENTO

Técnica 2: PCA (Análise de Componentes Principais)

O que faz: Reduz as 11 dimensões originais para 2 componentes principais.

Justificativa: Elimina a multicolinearidade (variáveis que dizem a mesma coisa, ex: pH e Acidez) e permite a visualização gráfica dos grupos em um plano 2D, facilitando a interpretação humana.

K-MEANS

O que é?

O **k-means** é um algoritmo de aprendizado não supervisionado (Unsupervised Learning) que busca formar grupos dentro de um conjunto de dados. Ele funciona iterativamente para atribuir cada ponto de dados a um de **k grupos**, minimizando a soma do quadrado das distâncias entre os pontos e o centroide (média) de seu cluster.

K-MEANS

Natureza do Objetivo

O objetivo principal do projeto era descobrir e classificar grupos de vinhos com perfis químicos semelhantes sem conhecimento prévio de suas categorias. Essa tarefa de agrupamento é intrinsecamente um problema de aprendizado não supervisionado, sendo o k-means o algoritmo mais fundamental e utilizado.

Simplicidade e Eficiência

O k-means é conhecido por sua simplicidade conceitual e alta eficiência computacional, especialmente em grandes conjuntos de dados. Isso torna a exploração inicial de agrupamentos rápida e eficaz.

K-MEANS

Interpretabilidade

Os centroides dos clusters (k-means) são fáceis de interpretar, pois representam os valores médios das características químicas para cada grupo. Isso permitiu a fácil caracterização dos perfis de vinho encontrados

Relevância para a Aplicação

A segmentação por perfil químico é uma forma de análise exploratória que busca padrões latentes. O k-means é excelente para isso e se alinha perfeitamente com a aplicação sugerida como um "filtro de controle de qualidade", onde vinhos podem ser rapidamente classificados em um dos perfis químicos estabelecidos.

K-MEANS

Configuração: K=2 (definido via método silueta).

Cluster 0:

Maior teor alcoólico (Média: 10.61%)


Menor acidez volátil (Média: 0.41) = QUALIDADE MÉDIA MAIOR

Cluster 1:


Menor teor alcoólico (Média: 10.32%)

Maior acidez volátil (Média: 0.59) = QUALIDADE MÉDIA MENOR


Análise de Silhueta para Determinar o K Ideal



1. Mapa dos Clusters (Visualização Padrão via PCA)



- Cluster 0 (Azul): 590 elementos
- Cluster 1 (Verde): 1009 elementos-
- Total de elementos 1599




ASSOCIAÇÃO

SE Teor Alcoólico \geq 10.5% E Acidez Volátil $<$ 0.65 g/dm³ ENTÃO classificar como Perfil Superior (Cluster 1)

SE Teor Alcoólico $<$ 10.5% OU Acidez Volátil \geq 0.70 g/dm³ ENTÃO classificar como Perfil de Entrada/Risco (Cluster 0).

SE o Álcool estiver entre 9.8% e 10.5% **E** os Sulfatos forem maiores que 0.60 g/dm³ **ENTÃO** o vinho ainda pode ser classificado no Perfil Superior.

Regras de Associação que definem os Clusters (Árvore de Decisão)



RESULTADOS

Química VS Paladar

O estudo confirmou que o teor alcoólico é o maior "driver" de qualidade percebida, enquanto a acidez volátil é o maior detrator.

Segurança

O modelo aprendeu sozinho a penalizar vinhos com alta acidez volátil. Isso valida o uso da IA como ferramenta de triagem para evitar que vinhos estragados cheguem ao mercado.

Analise Crítica

Acurácias perfeitas são impossíveis devido à subjetividade humana nas notas originais, mas o modelo químico é mais consistente e reproduzível.

CONCLUSÃO

Síntese

A mineração de dados provou ser eficaz para transformar a enologia em uma ciência de dados exata.

Contribuição Prática

Para produtores: Ajuste fino da fermentação para atingir os clusters "Premium".

Para segurança: Detecção automática de lotes anômalos antes do envase.

FONTES

- <https://archive.ics.uci.edu/dataset/186/wine+quality>
- <https://www.bbc.com/portuguese/articles/c620lqp7v76o>
- P. Cortez, A. Cerdeira, F. Almeida, T. Matos and J. Reis. Modeling wine preferences by data mining from physicochemical properties. In Decision Support Systems, Elsevier, 47(4):547-553, 2009.

OBRIGADO